
APPRENTISSAGE FÉDÉRÉ

Prédiction de Maladies Cardiaques

Sifeddine LEGNIOUI & Youssef SARRAF

Module : Optimisation – 2025/2026


1. Contexte & Problématique
2. Méthodologie & Architecture
3. Scénarios de Répartition (IID vs Non-IID)
4. Les Algorithmes de la Fédération
5. Résultats & Analyses
6. Conclusion & Perspectives

Une opportunité massive

L'intelligence artificielle peut révolutionner le diagnostic médical (détection précoce, médecine personnalisée).

La Réalité du Terrain

- ▶ Les données sont bloquées dans les hôpitaux.
- ▶ Méfiance quant au partage de données sensibles.
- ▶ Des lois strictes s'appliquent (RGPD, HIPAA).




Le Changement de Paradigme

"Ne déplacez pas les données vers le modèle. Déplacez le modèle vers les données."

- ▶ **Collaboration sécurisée** : Plusieurs hôpitaux entraînent une IA ensemble.
- ▶ **Zéro fuite** : Aucune donnée patient n'est jamais transmise sur le réseau.
- ▶ **Poids uniquement** : Seuls les *paramètres mathématiques* du réseau de neurones sont partagés et fusionnés.

Notre projet s'inscrit rigoureusement dans les exigences du Professeur :

- ✓ Données tabulaires (Maladies cardiaques)
- ✓ Réseau : Perceptron Multicouche (MLP)
- ✓ 8 clients simulés (Hôpitaux)
- ✓ 4 Algorithmes fédérés testés
- ✓ Partitions IID vs Non-IID
- ✓ Métriques claires (Accuracy, Perte)




Description du jeu de données

- ▶ **Taille** : 1 025 patients.
- ▶ **13 Attributs cliniques** : Âge, sexe, type de douleur (CP), cholestérol, ECG, etc.
- ▶ **Cible** : Classification binaire (0 = Sain, 1 = Maladie Cardiaque).

Prétraitement réalisé :

- ▶ **Encodage One-Hot** sur les variables catégorielles.
- ▶ **Standardisation Z-score** sur les variables continues pour faciliter l'entraînement.
- ▶ *Résultat* : Un vecteur de taille 23 pour chaque patient.

Un Perceptron Multicouche léger et optimal pour ce jeu de données.



- ▶ **Taille Totale** : $\sim 2\,600$ paramètres.
- ▶ **Poids mémoire** : Moins de 11 Ko (très rapide à envoyer aux hôpitaux).

IID (Independent and Identically Distributed)

Chaque hôpital reçoit un échantillon parfaitement représentatif de la population globale (50% malades, 50% sains).

- ▶ Simule des hôpitaux généralistes.
- ▶ Excellent pour la convergence algorithmique.




Figure: Distribution IID des classes

Non-IID (Distribution de Dirichlet $\alpha = 0.5$)

Certains hôpitaux n'ont presque que des patients malades (Spécialisés), d'autres que des cas sains.

- ▶ C'est le défi principal du FL !
- ▶ Crée un "Client Drift" : chaque hôpital se spécialise trop sur ses propres patients.




Figure: Distribution Non-IID asymétrique

1. **Local SGD (L'Isolation)** : Aucun serveur central. Chaque hôpital s'entraîne dans son coin. Référence basse (Baseline).
2. **FedAvg (Le Standard de Google)** : Le serveur collecte les modèles locaux, en fait une simple moyenne, et redistribue la moyenne.
3. **FedAdam (L'Accélération Adaptative)** : Le serveur garde une mémoire (inertie) des agrégations précédentes. Très rapide quand les données sont propres (IID).
4. **FedProx (Le Bouclier Non-IID)** : Ajoute un *ressort mathématique* (Régularisation Proximale) : empêche un hôpital d'altérer le modèle trop radicalement.

Algorithme	Précision IID	Précision Non-IID
Local SGD	81.3%	62.1%
FedAvg	91.8%	91.3%
FedAdam	92.4%	90.7%
FedProx	91.8%	91.7%

- **La collaboration fonctionne** : Passer de 62% à plus de 91% en Non-IID sans bouger une seule donnée patient.
- **Victoire de FedProx** : C'est le plus robuste face au déséquilibre massif des hôpitaux.




Figure: Pertes (Loss) en IID




Figure: Pertes (Loss) en Non-IID

Le Phénomène de "Dérive"

L'analyse de la norme L_2 prouve que FedProx maintient les modèles hospitaliers "groupés", là où Local SGD explose.




Figure: Évolution de la Divergence L_2

Un système taillé pour le monde réel


- ▶ 1 échange Hôpital-Serveur : ~ 10.6 Ko
- ▶ Volume pour 1 Round (8 Hôpitaux) : ~ 160 Ko
- ▶ Volume Total (15 Rounds) : ~ 2.45 Mo

Conclusion : Le poids total de tout l'entraînement collaboratif sur Internet pèse **moins lourd qu'une seule photo sur smartphone**. C'est idéal pour les infrastructures IT des hôpitaux.

1. **Mission Accomplie** : Réussite du diagnostic fédéré (Heart Disease) en respectant à 100% la vie privée.
2. **Option 4 Validée** : Tabulaire, MLP, 8 clients, 4 algorithmes, IID & Non-IID ont été analysés.
3. **Algorithme Gagnant** : **FedProx** démontre une stabilité supérieure en condition réelle hétérogène.

Perspectives Futures

- ▶ Ajouter la *Confidentialité Différentielle* (bruit statique) pour bloquer les attaques de rétro-ingénierie.
- ▶ Passer à l'imagerie médicale (CNN, IRM).



MERCI DE VOTRE ATTENTION

Avez-vous des questions ?